# 降维视觉：多层自适应格子域（Grid Domain）在 GUI 导航中的应用

## Dimensionality-Reduced Vision: Multilayer Adaptive Grid Domain for GUI Navigation

Name: Constant-Dalink
Location: Hubei, China
Contact: 13581432693@163.com / 13581432693
Independent Researcher

Preprint v1.0 — 2026

## 摘要

当前 GUI 智能体的一个常见方向，是通过整屏截图、视觉编码器与多模态大模型完成桌面状态理解，并进一步输出点击坐标或操作动作。这类方法具有较强的通用性，但通常伴随较高的 Token 成本、较大的算力开销以及较强的分辨率依赖。

本文提出 **Grid Domain（格子域）**，一种面向 GUI 导航的降维表示方法。其基本思想是：将连续二维 GUI 空间 $\Omega \subset \mathbb{R}^2$ 离散化为 1–8 层自适应网格，并把空间定位任务转写为文本原生的一维坐标代号生成问题。模型不再直接处理完整像素空间，而是输出诸如 `c C4`、`dr A1 D8` 一类短文本动作串，以完成 GUI 操作。

本文的主要工作包括：(1) 给出 Grid Domain 的形式化定义，包括多层网格划分、坐标序列化编码与像素逆映射；(2) 将 Constant-Dalink 不完备公式引入 GUI 视觉场景，说明 GUI 导航通常只需要激活最小可用视觉子集，而非完整图像语义；(3) 从信息论和动作空间约束出发，分析”二维图像到一维坐标代号”在文本生成模型下的表示优势；(4) 提出 **Grid + OCR-Light** 的轻量混合架构，使 OCR 只作为文本锚点提供器，而不承担完整视觉语义建模任务；(5) 与整屏截图驱动的 GUI 方案进行比较，讨论其在 Token 成本、可移植性、鲁棒性与端侧部署上的差异。

本文的目标不是构造一个通用视觉理解系统，而是为 GUI 导航给出一种更符合文本模型输出机制的状态表示。

**关键词**：GUI 智能体；视觉降维；格子域；OCR；桌面自动化；Token 经济学；动作空间压缩

## 1. 引言

### 1.1. 问题背景

让大语言模型执行桌面操作，表面上属于视觉任务，实际上更接近**空间指向与动作选择问题**。在多数 GUI 场景中，系统并不需要恢复整个屏幕的完整语义，而主要需要确定：

- 下一步应当把鼠标落在什么区域；
- 某个按钮或输入框大致位于何处；
- 当前操作目标属于哪个可执行单元。

因此，GUI 自动化中的关键问题通常不是”完整图像理解”，而是**在有限空间中做出稳定定位**。

现有方法，尤其是以整屏截图为输入的多模态方案，通常先将高维图像编码为视觉表示，再从中恢复低维动作信号。这一路径能够覆盖一般性场景，但在 GUI 导航中往往存在如下问题：

- 输入维度远高于动作决策实际所需维度；
- 每轮交互都需要重新获取和处理截图；
- 模型输出仍需从大范围像素空间中确定落点；
- 端侧部署成本较高。

### 1.2. 基本观点

本文的基本观点是：

> GUI 交互中的视觉表示，应当优先围绕可执行坐标代号构建，而不是围绕整图语义展开。

Grid Domain 的基本过程包括：

1. 在屏幕空间上定义分层网格；
2. 将连续区域离散为有限个单元格；
3. 为每个单元格分配简短文本代号；
4. 让模型直接生成这些代号，而不是回归像素坐标或解释完整截图。

在这种表示下，模型面对的不再是高维像素空间，而是一个有限、可枚举、可语言化的动作空间。

### 1.3. 理论位置

本文延续论文一中" 预测即调用" 的基本思路，并将 Constant-Dalink 不完备公式引入 GUI 视觉建模：

$$\forall \pm \{(V_1, V_2)^c, V_1, V_2, V, \dots\} \xrightarrow{\text{Check}} \circ V_{use}$$

在视觉场景下，这一公式意味着：

- 系统不需要在每一步都带入完整屏幕信息；
- 视觉输入应经过 Check 过程压缩为最小可执行子集；
- 最终进入动作决策的，应当是当前任务真正需要的定位信息，而不是全部图像内容。

Grid Domain 可以看作这一原则在 GUI 导航中的工程实现。

## 2. 相关工作

### 2.1. 基于 DOM 或结构树的 UI 自动化

较早期的 Web Agent 通常依赖 DOM 树、Accessibility Tree 或其他结构化页面表示。这类方法对 Web 场景有效，因为界面对象能够通过结构树显式暴露。

但其局限也较为明显：

1. 依赖界面底层结构是否可访问；
2. 难以统一覆盖桌面应用、原生窗口与跨平台 GUI；
3. 容易把大量与当前任务无关的节点一并带入上下文。

因此，这类方法更适合结构明确的 Web 环境，而不适合作为统一桌面 GUI 的通用表示。

### 2.2. 基于截图的多模态 GUI 智能体

另一类方法以整屏截图为核心输入，由视觉–语言模型完成界面理解并输出动作。Anthropic Computer Use [1] 是其中具有代表性的系统。

这一路线的主要特点是：

- 输入直接来自截图；
- 模型需同时完成视觉解析、目标识别与动作定位；
- 每步操作通常需要重新获取状态图像。

其代价包括：

- 输入熵高；
- 动作空间连续；
- 状态重采样频繁；
- 对分辨率、缩放和主题变化较为敏感。

### 2.3. 本文方法的定位

本文提出的 Grid Domain 不依赖 DOM 结构，也不以整屏视觉理解为中心，而是采用第三种表示路径，如表 **??** 所示。

## 3. Constant-Dalink 公式与视觉压缩基础

### 3.1. 公式在视觉系统中的含义

将 GUI 状态记为：

$$X = \{P, T, W, C, H, \dots\}$$

其中：

- $P$：像素场（pixels）；
- $T$：可识别文本；
- $W$：窗口边界与布局；
- $C$：控件候选区域；
- $H$：历史焦点与近期动作；
- $\dots$：其他可能相关的上下文。

基于整屏截图的方法通常倾向于加载接近整个 $X$ 的表示。而 Constant-Dalink 不完备公式表明，真正需要进入当前动作决策的，只应是一个很小的使用子集：

$$V_{use} \subset X, \qquad |V_{use}| \ll |X|$$

对 GUI 导航而言，这个 $V_{use}$ 往往只包括：

- 一个粗粒度的空间区域；
- 少量文本锚点；
- 当前层级深度；
- 一个最终点击代号。

因此，视觉系统的任务不是恢复全部图像语义，而是通过压缩映射

$$\Psi : X \xrightarrow{\text{Check}} V_{use}$$

把高维 GUI 状态转化为可执行的低维定位信息。

### 3.2. Grid Domain 作为视觉 Check 算子

在这一框架下，Grid Domain 可以写成一个视觉 Check 算子：

$$\Psi_{grid}(X) = \{\ell,\ g,\ A(g),\ O(g)\}$$

其中：

表 1: 三种 GUI 状态表示路径

| 路线 | 状态表示 | 动作表示 | 主要代价 |
|---|---|---|---|
| DOM / Tree | 结构树 | 元素选择 | 树结构冗余、平台依赖 |
| Screenshot-VLM | 全图像 | 像素坐标或自然语言动作 | 高 Token、高算力 |
| Grid Domain | 离散网格 | 坐标代号 | 低熵、低 Token |

- $\ell$：当前网格层级；
- $g$：目标单元格代号；
- $A(g)$：该单元格的邻接关系；
- $O(g)$：可选 OCR 锚点集合。

Grid Domain 的输出不是高维图像，而是足以支持动作执行的最小坐标语义。

### 3.3. 视觉不完备性的工程含义

由 Constant-Dalink 公式可得到一个直接原则：

> GUI 导航中的视觉模块，应优先保留完成当前动作所需的最小信息。

这也是本文采用格子化表示而非整图语义展开的原因。对桌面交互任务而言，目标通常是稳定定位，而不是构造完整视觉解释。

## 4. Grid Domain 的形式化定义

### 4.1. 屏幕空间

设屏幕为空间区域：

$$\Omega = [0, W) \times [0, H)$$

其中 $W, H \in \mathbb{N}^+$ 表示屏幕宽高。

### 4.2. 多层网格划分

定义层级集合：

$$L = \{1, 2, \ldots, 8\}$$

第 $\ell$ 层将屏幕均匀划分为 $2^\ell \times 2^\ell$ 个单元格。于是第 $\ell$ 层网格为：

$$\mathcal{G}_\ell = \{G^\ell_{i,j} \mid 1 \le i, j \le 2^\ell\}$$

其中每个单元格定义为：

$$G^\ell_{i,j} = \left[\frac{(j-1)W}{2^\ell}, \frac{jW}{2^\ell}\right) \times \left[\frac{(i-1)H}{2^\ell}, \frac{iH}{2^\ell}\right)$$

完整格子域定义为：

$$\mathcal{G} = \bigcup_{\ell=1}^{8} \mathcal{G}_\ell$$

### 4.3. 坐标代号序列化

为了适配文本生成模型，需要把二维单元格转写为一维文本代号。定义列编码函数 $\alpha(j)$ 与行编码函数 $\beta(i)$：

- $\alpha(j)$：将列号映射为字母序列（A, B, ..., Z, AA, AB, ...）；
- $\beta(i)$：将行号映射为十进制数字串（1, 2, ..., 256）。

进而定义序列化函数：

$$\xi_\ell : \mathcal{G}_\ell \to \Sigma^*$$

满足：

$$\xi_\ell(G^\ell_{i,j}) = \alpha(j)\beta(i)$$

例如：

$$G^3_{1,1} \mapsto \texttt{A1}$$
$$G^4_{4,3} \mapsto \texttt{C4}$$
$$G^6_{12,28} \mapsto \texttt{AB12}$$

这一步完成了从二维空间单元到一维语言串的映射，使 GUI 定位问题能够被表示为短文本生成问题。

### 4.4. 像素逆映射

点击执行时，需要将代号还原为实际像素坐标。定义逆映射中心函数：

$$\phi_\ell(G^\ell_{i,j}) = \left(\left\lfloor \frac{(2j-1)W}{2^{\ell+1}} \right\rfloor, \left\lfloor \frac{(2i-1)H}{2^{\ell+1}} \right\rfloor\right)$$

即使用单元格几何中心作为点击位置。

若输入为字符串代号 $s = \alpha(j)\beta(i)$，则：

$$\phi_\ell(s) = \phi_\ell(G^\ell_{i,j})$$

这对应工程实现中的 `cell_to_pixel()`。

### 4.5. 八层精度示例

以 1920×1080 屏幕为例，各层级对应的单元格大小如表 **??** 所示。

### 4.6. 自适应层选择

Grid Domain 并不要求始终使用第 8 层，而是根据任务所需精度选择最小足够层级。设目标容忍误差半径为 $\varepsilon$，若要求单元格最大边长不超过 $2\varepsilon$，则取最小 $\ell^*$ 满足：

$$\max\left(\frac{W}{2^\ell}, \frac{H}{2^\ell}\right) \le 2\varepsilon$$

即：

$$\ell^* = \min\left\{\ell \in L : \max\left(\frac{W}{2^\ell}, \frac{H}{2^\ell}\right) \le 2\varepsilon\right\}$$

工程上可简化为：

- 打开程序、切换窗口：$\ell = 2, 3$；
- 点击按钮或标签：$\ell = 4$；
- 点击输入框或菜单项：$\ell = 5$；
- 微小图标或密集表格：$\ell = 6 \sim 8$。

### 4.7. 复杂度

Grid Domain 的主要复杂度如下：

- 绘制网格：$O(4^\ell)$；
- 坐标到像素映射：$O(1)$；
- 字符串代号解析：$O(|s|)$；
- 模型输出长度：常数级。

因此，定位开销主要由所选层级决定，而不直接依赖图像内容复杂度。

## 5. 为什么”二维图像到一维坐标代号”更适合当前模型

这里所说的”更适合”，是指在当前自回归文本模型、有限上下文预算和有限算力条件下，Grid Domain 提供了一种更贴近模型输出机制的 GUI 表示。

### 5.1. 信息论下界

若第 $\ell$ 层网格中共有

$$K = 4^\ell$$

个候选单元格，则唯一确定其中一个目标至少需要

$$\log_2 K = 2\ell$$

bits 的信息量。

Grid Domain 直接使用单元格编号承载这部分信息，因此其空间表示接近定位任务本身的信息下界。例如：

- $\ell = 4$ 时，$K = 256$，需要 8 bits；
- $\ell = 5$ 时，$K = 1024$，需要 10 bits。

相比之下，完整截图携带的像素信息远高于动作决策所需的信息量。

### 5.2. 从连续回归到离散选择

像素级点击本质上是连续或高分辨率空间中的位置回归，而 LLM 的输出机制本质上是离散 token 生成。因此，把 GUI 动作直接定义在像素空间中，并不总是与模型的输出方式匹配。

设像素动作空间为：

$$\mathcal{A}_{pix} = \Omega$$

则其规模约为 $WH$。以 1920×1080 为例：

$$|\mathcal{A}_{pix}| \approx 2.07 \times 10^6$$

对应熵近似为：

$$H(\mathcal{A}_{pix}) \approx \log_2(WH) \approx 21 \text{ bits}$$

而格子域动作空间为：

$$\mathcal{A}^\ell_{grid} = \mathcal{G}_\ell$$

其熵为：

$$H(\mathcal{A}^\ell_{grid}) = \log_2(4^\ell) = 2\ell$$

当 $\ell = 4$ 时，仅为 8 bits。因此，模型需要选择的动作空间被显著压缩。

### 5.3. 离散动作熵降低定理

**定理 5.1** (离散动作熵降低). *在相同 GUI 定位目标下，若模型输出形式为文本自回归，则将动作空间从像素空间 $\mathcal{A}_{pix}$ 映射到格子空间 $\mathcal{A}^\ell_{grid}$，可将动作决策熵从 $\log_2(WH)$ 降低为 $2\ell$：*

$$\Delta H = \log_2(WH) - 2\ell > 0$$

以 1920×1080 屏幕、$\ell = 4$ 为例：

$$\Delta H \approx 21 - 8 = 13 \text{ bits}$$

表 2: 1920×1080 屏幕上的八层网格精度

| 层级 $\ell$ | 网格规模 | 单元格宽 × 高 | 典型用途 |
|---|---|---|---|
| 1 | 2×2 | 960×540 | 象限级导航 |
| 2 | 4×4 | 480×270 | 窗口级定位 |
| 3 | 8×8 | 240×135 | 图标或大区域 |
| 4 | 16×16 | 120×67 | 按钮级定位 |
| 5 | 32×32 | 60×34 | 文本框或菜单项 |
| 6 | 64×64 | 30×17 | 小控件 |
| 7 | 128×128 | 15×8 | 微型图标 |
| 8 | 256×256 | 7.5×4 | 高精度微调 |

这表明格子离散化在动作空间规模上带来了数量级压缩。

### 5.4. 坐标代号的最优阶表示

定义允许的表示类 $\mathcal{E}_{adm}$ 为所有满足以下条件的 GUI 表示方法：

1. 可由纯文本 token 序列表达；
2. 可唯一映射回一个可执行点击区域；
3. 不依赖完整图像语义展开；
4. 可在常数级上下文中复用。

则任意 $e \in \mathcal{E}_{adm}$，若需要在 $K$ 个目标中唯一指定一个目标，其最小编码长度满足：

$$|e| \geq \Omega(\log K)$$

而 Grid Domain 的坐标代号满足：

$$|e_{grid}| = O(\log K)$$

因此，在该表示类中，Grid Domain 在渐近意义上达到最优阶。

### 5.5. 稳定性的来源

Grid Domain 将 GUI 定位拆分为两个部分：

1. 系统侧完成离散化：把连续空间切分为命名单元格；
2. 模型侧完成选择：从命名单元格中选择目标。

与” 完整看图、识别、再回归坐标” 的流程相比，这一分解把更多不确定性转移到了确定性的几何层，从而提高了表示与执行之间的一致性。

## 6. Grid Domain 与 OCR-Light 的轻量融合

### 6.1. 纯格子方法的限制

纯格子表示已经足以完成大量几何定位任务，但在以下情形中仍存在不足：

- 目标依赖文字标签而非显著几何特征；
- 例如” 保存”” 发送”” 确定”” 下一步” 等按钮，位置和样式可能变化，但文字本身具有较稳定语义。

因此，本文引入 **OCR-Light**，作为格子域的辅助文本锚点模块。

### 6.2. OCR 输出形式

定义 OCR 结果集为：

$$\mathcal{R} = \{(b_i, \tau_i, q_i)\}_{i=1}^{n}$$

其中：

- $b_i = (x_i^1, y_i^1, x_i^2, y_i^2)$：文本框边界；
- $\tau_i$：识别文本；
- $q_i$：置信度。

对每个文本框，定义其中心点：

$$c_i = \left(\frac{x_i^1 + x_i^2}{2}, \frac{y_i^1 + y_i^2}{2}\right)$$

再映射到第 $\ell$ 层格子：

$$g_i = \pi_\ell(c_i)$$

其中 $\pi_\ell$ 为点到单元格的归属函数。

于是 OCR 输出可转写为：

$$(\tau_i,\ g_i,\ q_i)$$

例如：

(保存, D11, 0.98)
(发送, F9, 0.95)

### 6.3. 混合提示格式

最终提供给模型的不是截图，而是轻量文本状态，例如：

```
grid:l4
ocr:
保存 D11
取消 F11
发送 F9
task: 点击保存
```

模型输出：

```
c D11
```

### 6.4. OCR-Light 的约束原则

OCR-Light 仍需遵守 Constant-Dalink 原则，只保留必要文本锚点。记有效 OCR 子集为：

$$\mathcal{R}_{use} = \mathrm{TopK}\{(\tau_i, g_i, q_i)\}$$

通常只保留：

- 与任务语义最相关的文本；
- 置信度较高的前 $k$ 项；
- 当前区域附近的候选项。

因此，OCR 在该架构中是辅助定位模块，而不是主视觉通道。

### 6.5. 混合模式的作用

三种模式可以概括为表 **??**。

这种混合方式在保持低熵表示的同时，也提高了对按钮文字、表单标签和网页菜单项的处理能力。

## 7. 与整屏截图驱动方案的比较

### 7.1. 比较前提

本文并不否认视觉模型在 GUI 任务中的可用性。关键问题不在于" 是否能够看图"，而在于：**对于以空间点击为主的任务，是否有必要在每一步都使用高成本的整图理解。**

Grid Domain 的出发点是：如果一个任务可以通过几何离散与少量文本锚点完成，那么整图视觉建模未必是成本最优路径。

### 7.2. 状态表示差异

### 7.3. Token 成本比较

设截图编码成本为 $S_{img}$，OCR 锚点成本为 $S_{ocr}$，格子状态成本为 $S_{grid}$。则典型情况下：

- 整屏截图方案：

$$C_{vision} = S_{img} + S_{instr} + S_{hist}$$

往往在数千 Token 量级；

- Grid Domain：

$$C_{grid} = S_{grid} + S_{ocr} + S_{task} + S_{cmd}$$

通常保持在数十到百余 Token 范围。

两者在上下文规模上通常存在明显差异。

### 7.4. 误差来源比较

整屏截图方案的误差可能来自：

1. 元素误识别；
2. 坐标定位偏差；
3. 分辨率与缩放变化；
4. 图中文字识别波动；
5. 多轮截图状态不一致。

Grid Domain 的误差主要集中在：

1. 单元格选择错误；
2. 层级选择错误；
3. OCR 锚点识别错误。

后者仍可能失败，但错误空间通常更集中，也更容易通过重试、层级调整和显式规则进行修正。

### 7.5. 端侧部署差异

整屏截图驱动方案通常需要：

- 图像编码能力；
- 较高显存与吞吐；
- 高频状态重采样。

Grid Domain 主要需要：

- 文本模型；
- 坐标代号生成；
- 常数级上下文窗口。

因此，在中小模型与端侧环境下，Grid Domain 更容易部署。

表 3: 纯视觉、纯格子与混合模式比较

| 模式 | 优点 | 局限 |
|---|---|---|
| 纯视觉截图 | 语义信息丰富 | 计算和上下文成本高 |
| 纯格子 | 极轻、稳定 | 不直接处理文字语义 |
| 格子 + OCR-Light | 低 Token + 文本锚点 | 依赖轻量 OCR 质量 |

表 4: 整屏截图方案与 Grid Domain 的状态表示差异

| 维度 | 整屏截图方案 | Grid Domain |
|---|---|---|
| 状态输入 | 全屏截图 | 当前层级 + 可选 OCR 锚点 |
| 状态维度 | $O(WH)$ | $O(1)$ 到 $O(k)$ |
| 模型任务 | 视觉解析 + 定位 + 行动 | 单元格选择 + 行动 |
| 输出形式 | 像素坐标或自然语言动作 | 坐标代号 |

## 8. 工程实现与实验设计建议

### 8.1. grid.py 的核心组件

工程上可将 Grid Domain 划分为以下模块：

1. `make_grid(level)`：生成第 $\ell$ 层网格；
2. `cell_to_pixel(code, level)`：代号到像素中心映射；
3. `pixel_to_cell(x, y, level)`：像素到代号映射；
4. `show(level)`：透明叠加渲染；
5. `choose_level(task_type, target_size)`：自适应层选择。

### 8.2. 评估指标

实验中建议使用以下指标：

- **Click Success@1**：单次点击命中率；
- **Task Success**：任务级成功率；
- **Token per Step**：每步 Token 成本；
- **Localization Error**：定位误差；
- **Time to First Action**：首次动作时间；
- **Resolution Robustness**：分辨率鲁棒性。

### 8.3. 基准任务集

建议至少覆盖以下任务：

1. 打开应用；
2. 点击窗口按钮；
3. 选择菜单项；
4. 定位输入框并输入文本；
5. 借助 OCR 锚点点击” 保存 / 发送 / 确定”；
6. 在小图标密集场景下完成高层级精确点击。

### 8.4. 对照组设计

可设置如下对照组：

- VLM-Screenshot Agent；
- OCR-only Agent；
- Grid-only Agent；
- Grid + OCR-Light Agent。

预期现象通常包括：

- Grid-only 在几何目标上较为稳定；
- Grid + OCR-Light 在文字目标上更有优势；
- Screenshot Agent 成本较高，且对环境变化更敏感。

## 9. 局限性与结论

### 9.1. 局限性

本文仍有若干局限：

1. **不是通用视觉语义模型**：Grid Domain 的目标是 GUI 导航与交互，不覆盖图像内容理解、视频语义分析或复杂图形编辑中的像素级语义推理。
2. **极小目标仍需更高精度策略**：对于 1–3 像素级目标，仅靠全局网格可能仍存在误差，需要局部放大、二次格子或鼠标微调策略。
3. **OCR 仍可能误识别**：OCR-Light 在字体复杂、遮挡明显或透明按钮场景下仍可能出现识别错误，但相较完整视觉理解，其误差来源通常更集中。

### 9.2. 结论

本文提出了 Grid Domain，一种将 GUI 视觉任务从高维截图表示转写为低维坐标代号选择的表示框架。

表 5: 本文主要结论

| # | 结论 | 含义 |
|---|---|---|
| 1 | GUI 导航本质上是低熵空间选择问题 | 不需要始终展开完整图像语义 |
| 2 | 1–8 层格子可覆盖常见桌面交互精度 | 从窗口级到高精度微调 |
| 3 | 二维图像到一维坐标代号的映射更适合文本生成模型 | 与自回归输出机制更一致 |
| 4 | Grid Domain 满足 Constant-Dalink 的最小使用集原则 | 只激活必要视觉变量 $V_{use}$ |
| 5 | Grid + OCR-Light 提供较好的成本–效果折中 | 低 Token、较低计算负担、较强端侧可行性 |

核心结论可概括如下：

本文的中心观点是：GUI 交互中的不稳定性，不仅来自模型能力本身，也来自表示方式与任务结构之间的不匹配。

当模型需要处理完整截图并隐式回归连续坐标时，任务形式与文本生成机制之间存在偏差；而当 GUI 空间被离散为可直接生成的坐标代号时，定位问题可以更自然地转化为离散选择问题。

从这个意义上说，Grid Domain 的作用不是增加视觉理解能力，而是将 GUI 状态改写为更适合文本模型处理的形式。

## 参考文献


[1] Anthropic. Developing a Computer Use Model. *Anthropic Research Blog*, 2024.

[2] OpenAI. Function Calling and Other API Updates. 2023.

[3] Tom B. Brown et al. Language Models are Few-Shot Learners. *NeurIPS*, 2020.

[4] Claude E. Shannon. A Mathematical Theory of Communication. 1948.

[5] Marvin Minsky. Computation: Finite and Infinite Machines. 1967.

[6] Shunyu Yao et al. ReAct: Synergizing Reasoning and Acting in Language Models. *ICLR*, 2023.

[7] Timo Schick et al. Toolformer: Language Models Can Teach Themselves to Use Tools. *NeurIPS*, 2023.

[8] GSS-OS Internal Notes. Constant-Dalink Incompleteness Formula and Cognitive Compression. 2025.


## A. Grid Domain 速查定义

### A.1. 核心映射

$$\Omega = [0, W) \times [0, H)$$

$$\mathcal{G}_\ell = \{G^\ell_{i,j} \mid 1 \le i, j \le 2^\ell\}$$

$$\xi_\ell(G^\ell_{i,j}) = \alpha(j)\beta(i)$$

$$\phi_\ell(G^\ell_{i,j}) = \left(\left\lfloor \frac{(2j-1)W}{2^{\ell+1}} \right\rfloor, \left\lfloor \frac{(2i-1)H}{2^{\ell+1}} \right\rfloor\right)$$

### A.2. 与 Constant-Dalink 的对应

$$X = \{P, T, W, C, H, \dots\} \xrightarrow{\Psi_{grid}} V_{use} = \{\ell, g, O(g)\}$$

即：

- $P$ 不需要整体进入模型；
- $T$ 只保留 OCR 锚点；
- 最终动作主要由 $g$ 决定。

## B. 最小提示词示例

```
grid:14
ocr:
保存 D11
取消 F11
task: 点击保存按钮
```

模型输出：

```
c D11
```